




Fundamentos del ML

AI vs ML vs DL





Una tarea sencilla: Image Classification

Image Classification





Image Classification







Image Classification



Obstrucciones





Image Classification



Desorden de fondo





Cute



And Kittens



Clipart



Drawing



Cute Baby



White Cats And Kittens



Pose



Iluminación

Aspecto





Un Clasificador Simple

Nearest Neighbor



Nearest Neighbor



Nearest Neighbor

NN clasificador = perro



distancia
Inteligencia Artificial 2024

Nearest Neighbor



KNN clasificador = gato




distancia


Nearest Neighbor




Los datos



Clasificador NN



Clasificador 5NN




Fuente: <https://commons.wikimedia.org/wiki/File:Data3classes.png>

Inteligencia Artificial 2024


Nearest Neighbor




Los datos



Clasificador NN



Clasificador 5NN



¿Cómo funciona el clasificador NN en los datos de entrenamiento?

¿Qué clasificador tiene más probabilidades de obtener mejores resultados en la test data?



Nearest Neighbor

- **Hiperparámetros**
 - Distancia L1 : $|x - c|$
 - Distancia L2 : $||x - c||_2$
 - Número de vecinos: k
- Los hiperparámetros dependen del problema.
- Cómo elegimos estos hiperparámetros?




Machine Learning for Classification

Machine Learning



- $M_{\theta}(I) = \{\text{DOG}, \text{CAT}\}$



CAT



DOG



DOG



CAT

CAT




DOG

Machine Learning



- $M_{\theta}(I) = \{\text{DOG}, \text{CAT}\}$



$$\theta^* = \underset{\theta}{\operatorname{argmin}} \sum_i D(M_{\theta}(I_i) - Y_i)$$

"Distance" function

$\{\text{DOG}, \text{CAT}\}$



DOG



DOG



CAT



DOG



Receta básica para el ML

- Divida los datos




Encuentre los parámetros
del modelo θ

También son posibles otras divisiones (por ejemplo,
80%/10%/10%)

Receta básica para el ML

- Divida los datos



Encuentre sus hiperparámetros

También son posibles otras divisiones (por ejemplo, 80%/10%/10%)



Receta básica para el ML

- Divida los datos

60% 20% 20%



**Test set solo se utiliza
una vez**

tros

Machine Learning



Aprendizaje no supervisado

Aprendizaje supervisado


- **Labels o clases objetivo**

Machine Learning



Aprendizaje no supervisado

Aprendizaje supervisado



DOG




DOG



CAT

CAT



DOG

Machine Learning



Aprendizaje no supervisado

- Sin labels ni clase objetivo
- Encontrar propiedades de la estructura de los datos
- Agrupación (k-means, PCA, etc.)

Aprendizaje supervisado



DOG



DOG



CAT

CAT

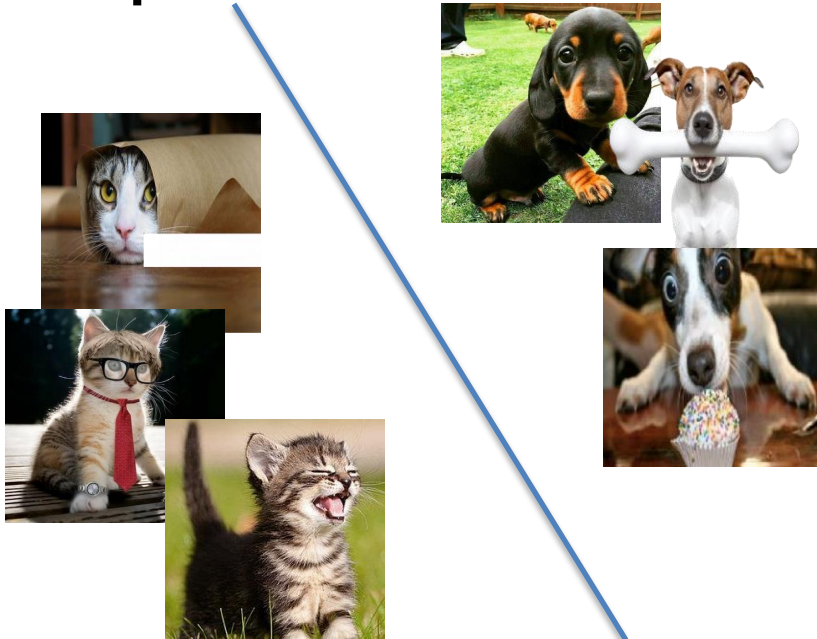


PER
RO

Machine Learning



Aprendizaje no supervisado




Aprendizaje supervisado



Machine Learning



Aprendizaje no supervisado



Aprendizaje supervisado



CAT



DOG



PER
RO



CAT



DOG

Machine Learning



Aprendizaje no supervisado



Aprendizaje supervisado



Machine Learning



Aprendizaje no supervisado



Aprendizaje supervisado



Reinforcement Learning



Machine Learning



Aprendizaje no supervisado



Aprendizaje supervisado



Reinforcement Learning



Machine Learning



Aprendizaje no supervisado **Aprendizaje supervisado**



Aprendizaje por
refuerzo






Regresión lineal

Regresión lineal



- Aprendizaje supervisado
- Encontrar un modelo lineal que explique un output y dados los input x



Predicción lineal

- Un modelo lineal se expresa de la siguiente forma:

$$\hat{y}_i = \sum_{j=1}^d x_{ij} \theta_j$$

Diagram illustrating the linear model equation $\hat{y}_i = \sum_{j=1}^d x_{ij} \theta_j$ with annotations:

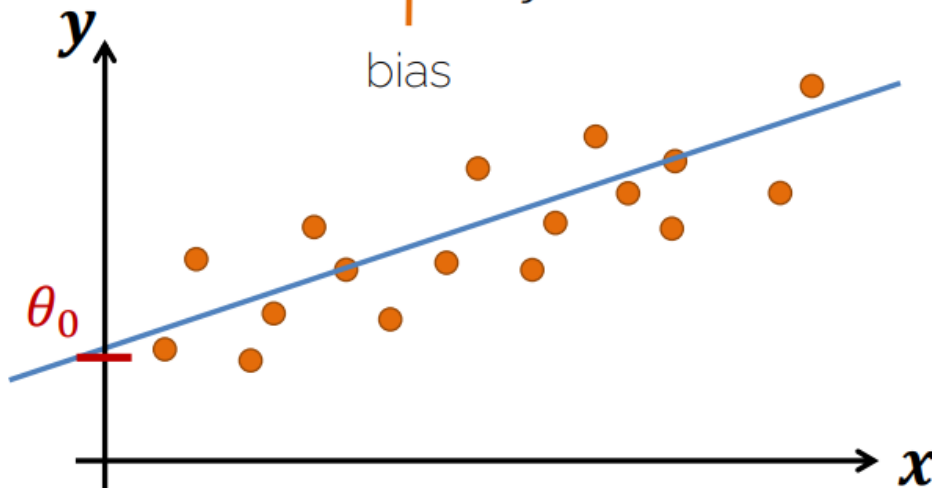
- d : input dimension (indicated by a purple arrow pointing to the upper limit of the summation).
- x_{ij} : Input data, features (indicated by an orange arrow pointing to the term x_{ij}).
- θ_j : weights (i.e., model parameters) (indicated by a blue arrow pointing to the term θ_j).

Predicción lineal

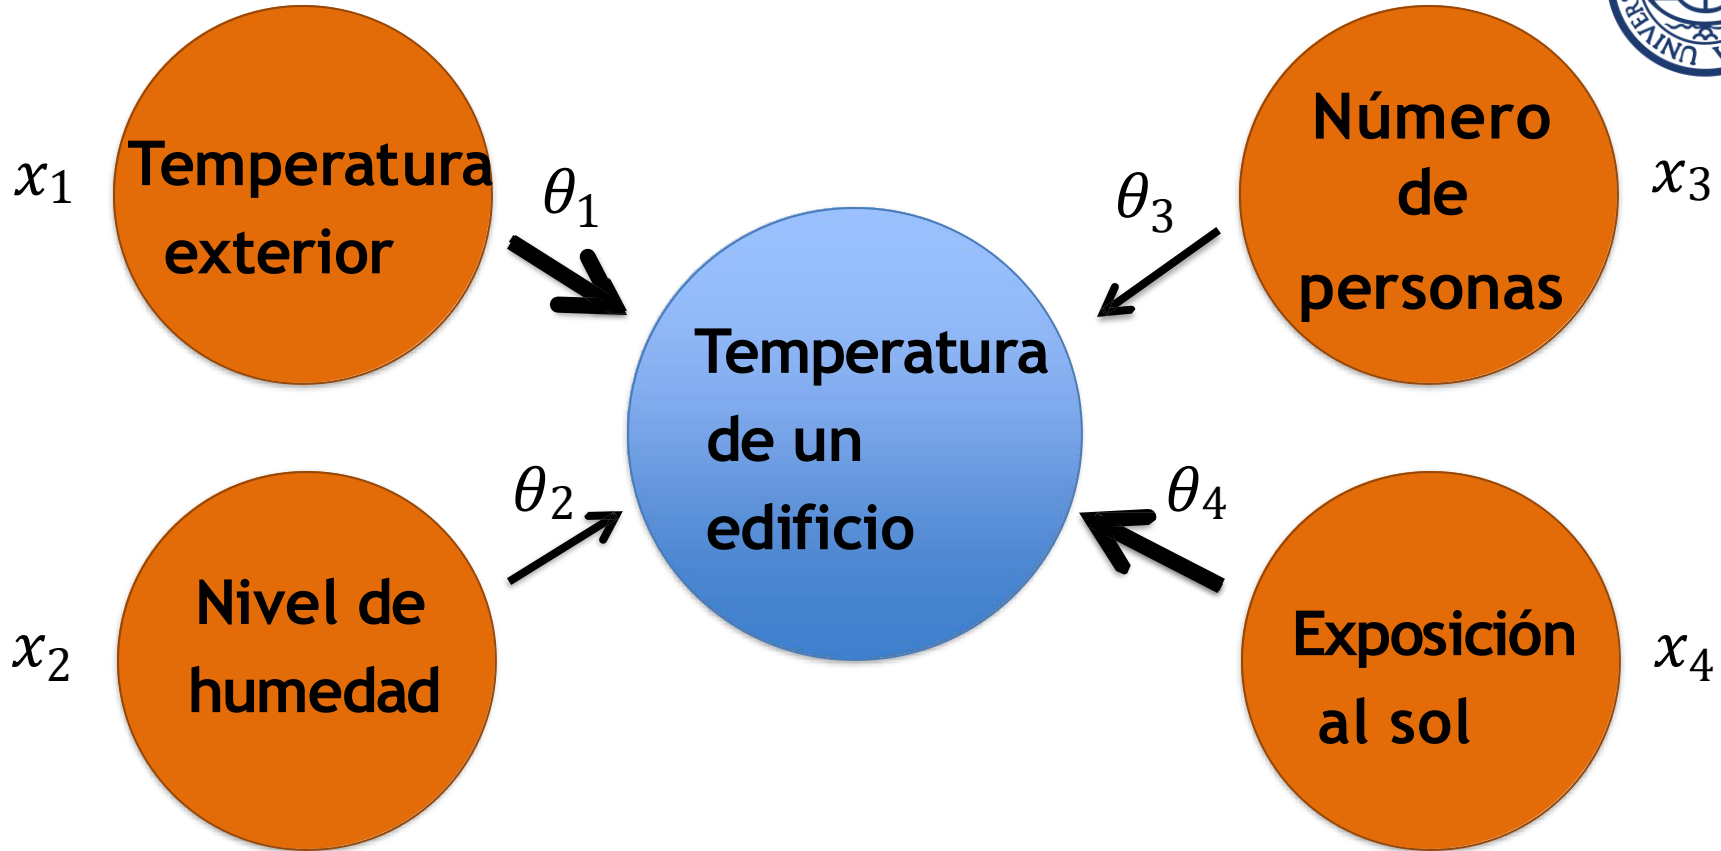
- Un modelo lineal se expresa de la forma

$$\hat{y}_i = \boxed{\theta_0} + \sum_{j=1}^d x_{ij}\theta_j = \theta_0 + x_{i1}\theta_1 + x_{i2}\theta_2 + \dots + x_{id}\theta_d$$

↑
bias



Predicción lineal



Predicción lineal

$$\begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix} = \theta_0 + \begin{bmatrix} x_{11} & \cdots & x_{1d} \\ x_{21} & \cdots & x_{2d} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nd} \end{bmatrix} \cdot \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix}$$



$$\begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1d} \\ 1 & x_{21} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{nd} \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_d \end{bmatrix}$$

$$\Rightarrow \hat{\mathbf{y}} = \mathbf{X}\boldsymbol{\theta}$$

Predicción lineal



Temperatura
del edificio

$$\begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \end{bmatrix}$$

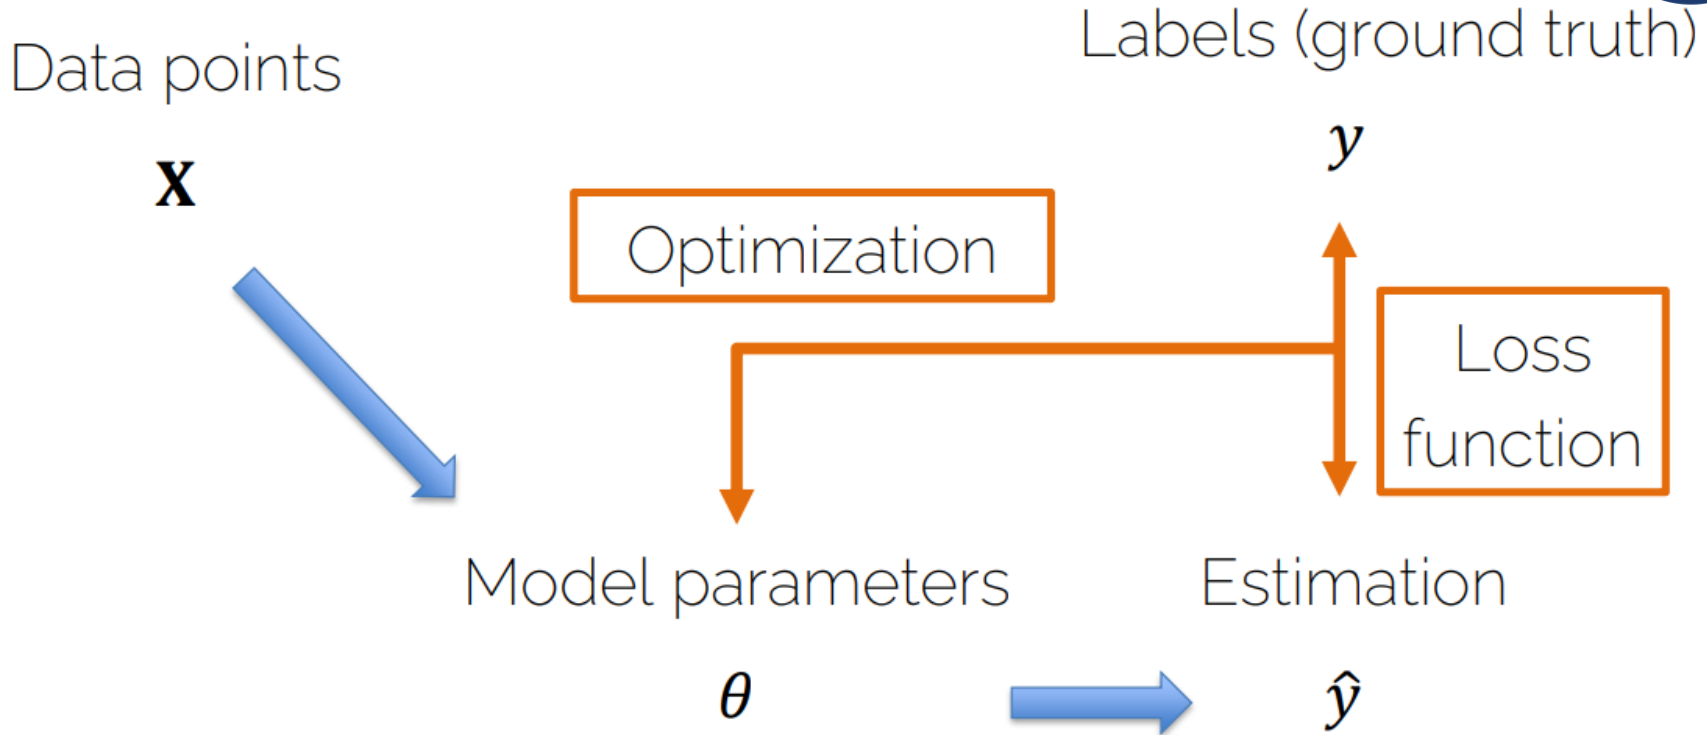
=

	Bias	Outside temperature	Humidity	Number people	Sun exposure (%)	
	1	25	50	2	50	·
	1	-10	50	0	10	
						0
						1
						0.14

MODELO

$\begin{bmatrix} 0.2 \\ 0.64 \\ 0 \\ 1 \\ 0.14 \end{bmatrix}$

¿Cómo obtener el modelo?




¿Cómo obtener el modelo?




- **Función de pérdida:** mide lo buena que es mi estimación (lo bueno que es mi modelo) e indica al método de optimización cómo mejorarlo.
- **Optimización:** modifica el modelo para mejorar la función de pérdida (mejorar mi estimación).

Regresión lineal: Loss Function



**Predicción:
Temperatura
del edificio**

Regresión lineal: Loss Function



**Predicción:
Temperatura
del edificio**

Minimización

**Función objetivo Energía
Función de coste**



Optimización: Cuadrados Mínimos

- Cuadrados mínimos lineales: enfoque para ajustar un modelo lineal a los datos

$$\min_{\theta} J(\theta) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

- Problema convexo, existe una solución de forma cerrada que es única. Es decir, hay un óptimo único

Optimización



$$\frac{\partial J(\theta)}{\partial \theta} = 2\mathbf{X}^T \mathbf{X} \theta - 2\mathbf{X}^T \mathbf{y} = 0$$

$$\theta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Hemos
encontrado una
solución
analítica a un
problema
convexo

Inputs: Temperatura
exterior, número de
personas, ..

True Output:
Temperatura
del edificio

¿Es ésta la mejor estimación?



- Estimación por cuadrados mínimos

$$\min_{\theta} J(\theta) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$



Maximum Likelihood

Estimación de Maximum Likelihood (MLE)



$p_{data}(\mathbf{y}|\mathbf{X})$

**Verdadera distribución
subyacente**



$p_{model}(\mathbf{y}|\mathbf{X}, \theta)$

**Familia paramétrica de
distribuciones**



**Controlada por
parámetro(s)**

Estimación de Maximum Likelihood



- Método de estimación de los parámetros de un modelo estadístico dadas las observaciones,

$p_{model}(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta})$

Observaciones de $p_{data}(\mathbf{y}|\mathbf{X})$

Estimación de Maximum Likelihood



- Método de estimación de los parámetros de un modelo estadístico dadas las observaciones, encontrando los valores de los parámetros que **MAXIMIZAN LA PROBABILIDAD** de realizar las observaciones.

$$\theta_{ML} = \arg \max_{\theta} p_{model}(\mathbf{y}|\mathbf{X}, \theta)$$

Estimación de Maximum Likelihood





$$\theta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Regresión lineal



- La estimación de máxima verosimilitud (MLE) corresponde a la estimación por cuadrados mínimos (dados los supuestos)
- Introducción a los conceptos de función de pérdida y optimización para obtener el mejor modelo de regresión

Image Classification



Regression vs Clasificación




- **Regresión:** predecir un valor de salida continuo (por ejemplo, la temperatura de una habitación)
- **Clasificación:** predice un valor discreto
 - Clasificación binaria: la salida es 0 ó 1
 - Clasificación multiclase: conjunto de N clases



Regresión logística



Sigmoide para predicciones binarias



$$\sigma(x) = \frac{1}{1 + e^{-x}}$$


1

Puede interpretarse como una probabilidad

0

$$p(y = 1 | \mathbf{x}, \boldsymbol{\theta})$$

Red neuronal de 1 capa



$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

1



0

Puede interpretarse como una probabilidad


$$p(y = 1 | \mathbf{x}, \boldsymbol{\theta})$$

Regresión logística

- Probabilidad de una salida binaria

$$\hat{\mathbf{y}} = p(\mathbf{y} = 1 | \mathbf{X}, \boldsymbol{\theta}) = \prod_{i=1}^n p(y_i = 1 | \mathbf{x}_i, \boldsymbol{\theta})$$

The prediction of
our sigmoid


$$\hat{y}_i = \sigma(\mathbf{x}_i \boldsymbol{\theta})$$

Regresión logística: Loss Function



- Probability of a binary output

$$p(y|\mathbf{X}, \boldsymbol{\theta}) = \hat{\mathbf{y}} = \prod_{i=1}^n \hat{y}_i^{y_i} (1 - \hat{y}_i)^{(1-y_i)}$$

- Maximum Likelihood Estimate

$$\boldsymbol{\theta}_{ML} = \arg \max_{\boldsymbol{\theta}} \log p(y|\mathbf{X}, \boldsymbol{\theta})$$

Regresión logística: Loss Function



$$p(y|\mathbf{X}, \boldsymbol{\theta}) = \hat{y} = \prod_{i=1}^n \hat{y}_i^{y_i} (1 - \hat{y}_i)^{(1-y_i)}$$

$$\sum_{i=1}^n \log (\hat{y}_i^{y_i} (1 - \hat{y}_i)^{(1-y_i)})$$

$$\sum_{i=1}^n y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)$$

Regresión logística: Loss Function



$$\mathcal{L}(\hat{y}_i, y_i) = -[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]$$

Regresión logística: Loss Function



$$\mathcal{L}(\hat{y}_i, y_i) = -[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]$$

Denominada pérdida de *entropía cruzada binaria* (BCE)

- Relacionada con la multi-class los que lo vamos a ver (también llamada *softmax loss*)

Regresión logística: Optimización



- Loss function

$$\mathcal{L}(\hat{y}_i, y_i) = -[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]$$

- Cost function

$$C(\theta) = -\frac{1}{n} \sum_{i=1}^n \mathcal{L}(\hat{y}_i, y_i)$$

Minimization

$$= -\frac{1}{n} \sum_{i=1}^n y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)$$

$$\hat{y}_i = \sigma(\mathbf{x}_i \boldsymbol{\theta})$$

Regresión logística: Optimización



- No hay solución de forma cerrada
- Utilizar un método iterativo → gradient descent

gradient descent -
más adelante

Por qué está bueno el Machine Learning



- Podemos aprender de la experiencia
 - > Inteligencia, cierta capacidad para inferir el futuro
- Incluso los modelos lineales suelen ser bastante buenos para fenómenos complejos: por ejemplo, el tiempo atmosférico.



Parte Práctica

- Ejercicio de esta semana: Math Recap II
- Próxima clase:
 - Introducción a Redes Neuronales y Grafos computacionales

Referencias para lecturas complementarias



Cross Validation:

- <https://medium.com/@zsstern/k-fold-cross-validation-explained-5aeba90ebb3>
- <https://towardsdatascience.com/train-test-split-and-validación-cruzada-en-python-80b61beca4b6>

Libro de General Machine Learning:

- Reconocimiento de patrones y ML. C. Bishop.



Hasta la semana que
viene 😊