

Tutorial 9: Facial Keypoint Detection

CATOLICA PROCE


Overview

- Fully Connected & Convolutional Layers
 - Repaso
 - Cambios a Dropout & BatchNorm
- Ejercicio 9: Facial Keypoint Detection



Repaso: Fully Connected Layers


• Fully Connected Layers: Cada capa está formada por un conjunto de neuronas, donde cada neurona individual está conectada a todas las neuronas de la capa anterior.



CATOLICA PROCE

Computer Vision - FN

- Suposición: La entrada a la red son imágenes
- Inconveniente: las imágenes deben tener cierta resolución para contener suficiente información.




• ¿Podemos reducir el número de parámetros de nuestra arquitectura?

CATOLICA PROCES

Computer Vision - CNN


- Suposición: La entrada a la red son imágenes
- Idea: Filtro deslizante sobre la imagen de entrada (convolución) en lugar de pasar toda la imagen por todas las neuronas individualmente.



CATOLICA PROCES


Computer Vision - CNN

- Suposición: La entrada a la red son imágenes
- Filtros: Ventana deslizante con los mismos parámetros de filtro para extraer características de la imagen.
- Ventaja: aprender "conceptos" invariantes de la posición en la imagen y reparto de parámetros











Convolutional Layers: BatchNorm y Dropout



Repaso: Batch Normalization

- Batch Norm para redes neuronales FC
 - Tamaño de entrada (N, D)
 - Calcular la media y la varianza de los minibatches en N (es decir, nosotros calcular media/var para cada dimensión de característica)

Input:
$$x: N \times D$$

Learnable params:

$$\gamma, \beta: D$$

Intermediates:
$$\begin{pmatrix} \mu, \sigma : D \\ \hat{x} : N \times D \end{pmatrix}$$

Output:
$$y: N \times D$$

$$\mu_j = \frac{1}{N} \sum_{i=1}^{N} x_{i,j}$$

$$\sigma_j^2 = \frac{1}{N} \sum_{i=1}^N (x_{i,j} - \mu_j)^2$$

$$\hat{x}_{i,j} = \frac{x_{i,j} - \mu_j}{\sqrt{\sigma_j^2 + \varepsilon}}$$

$$y_{i,j} = \gamma_j \hat{x}_{i,j} + \beta_j$$



Repaso: Batch Normalization

- Batch Norm para redes neuronales FC
 - Tamaño de entrada (N, D)
 - Calcular la media y la varianza de los minibatches en N (es decir, nosotros calcular media/var para cada dimensión de característica)

Batch Normalization for fully-connected networks

```
x: N × D

Normalize \downarrow

\mu, \sigma: 1 × D


\gamma, \beta: 1 × D


\gamma = \gamma(x-\mu)/\sigma+\beta
```



Spatial Batch Normalization

- BatchNorm para Convolutional NN = spacial batchnorm
 - Tamaño de entrada (N, C, W, H)
 - Calcular la media y la varianza de los minilotes en N, W, H (esdecir, calculamos la media/var para cada canal C).







Spatial Batch Normalization

Fully Connected

- Input size (N, D)
- Compute minibatch mean and variance across N (i.e. we compute mean/var for each feature dimension)

x: N × D

Normalize

$$\mu, \sigma$$
: 1 × D

 γ, β : 1 × D

 $\gamma = \gamma(x-\mu)/\sigma + \beta$

Convolutional = spatial BN

- Input size (N, C, W, H)
- Compute minibatch mean and variance across N, W, H (i.e. we compute mean/var for each channel C)

Normalize
$$\mathbf{x}: \mathbf{N} \times \mathbf{C} \times \mathbf{H} \times \mathbf{W}$$
 $\mu, \sigma: \mathbf{1} \times \mathbf{C} \times \mathbf{1} \times \mathbf{1}$
 $\gamma, \beta: \mathbf{1} \times \mathbf{C} \times \mathbf{1} \times \mathbf{1}$
 $\gamma = \gamma(\mathbf{x} - \mu) / \sigma + \beta$





- Regular Dropout: Desactivación de neuronas específicas en el redes (una neurona "mira" toda la imagen)
- **Dropout Convolutional Layers**: El Dropout estándar a nivel de neurona (esdecir, el Dropout aleatorio de una unidad con una probabilidad determinada) no mejora el rendimiento en NN convolucionales.

 Standard Dropout
- Spatial Dropout: aleatoriamente pone en cero completos feature maps

Spatial Dropout





Dropout for convolutional layers

```
def dropout mlp():
    m = nn.Dropout(p=0.5)
    batch size = 1
    inputs = torch.randn(batch size, 3 * 5 *
    outputs = m(inputs)
    print(outputs)
    tensor([[
        -0.89, 0.37, -0.00, 0.00, -0.08, -0.00,
       0.00, -3.55, 0.00, 0.47, -0.00, 5.08,
        -0.00, -0.00, 2.63, 0.00, 0.00, 0.00,
       2.18, 1.92, -0.00, 0.66, 1.96, 0.00,
        -0.00, -0.00<u>, 0.00</u>, 1.31, -1.95, -0.00,
       0.00, -4.44, 0.00, -1.07, -0.90, -0.07,
       -3.81, 0.00, 0.23, 2.38, -2.27, -0.51,
       -3.32, -0.00, -0.65, 0.00, -0.00, <u>-0.00</u>,
        -0.00, -0.00, -0.61, 0.00, 0.00, 0.00,
       <u>-1.85</u> -0.40, 0.00, 0.68, -0.00, -1.96,
       -0.00. -1.65, 0.00, -0.66, 3.10, 0.00,
        -0.00, 1.89, 0.00, -1.28, 1.62, -0.56,
        -0.00, -0.00, -0.99]])
```

```
def dropout cnn():
   m = nn.Dropout2d(p=0.5)
   batch size = 1
   inputs = torch.randn(batch size, 3, 5 * 5)
   outputs = m(inputs)
   print(outputs)
   tensor([[
        [0.03, 1.40, 1.76, -4.34, -0.63,
        -0.31, 2.80, 2.72, -3.00, 2.67,
         -2.31, -3.45, 0.95, 1.18, 1.18,
         -1.05, 0.74, 3.56, 0.55, -1.19,
        [0.00, -0.00, -0.00, -0.00, -0.00]
         0.00, -0.00, -0.00, -0.00, 0.00,
         -0.00, 0.00, 0.00, -0.00, -0.00,
         0.00, -0.00, 0.00, 0.00, -0.00,
         -0.00, 0.00, -0.00, 0.00, 0.00],
         0.00, -0.00, -0.00, -0.00, 0.00,
         0.00, 0.00, 0.00, -0.00, -0.00,
         -0.00, -0.00, 0.00, -0.00, -0.00,
         0.00, 0.00, 0.00, -0.00, 0.00,
         -0.00, -0.00, 0.00, 0.00, -0.00]]]])
```



Ejercicio 9: Facial Keypoint Detection



Submission: Facial Keypoints

Input: Output: (1, 96, 96) grayscale image (2, 15) keypoint coordinates



Submission: Metric

Accuracy (Classification) → Score (Regression)

```
def evaluate_model(model, dataset):
   model eval()
    criterion = torch.nn.MSELoss()
   dataloader = DataLoader(dataset, batch_size=1, shuffle=False)
    loss = 0
    for batch in dataloader:
        image, keypoints = batch["image"], batch["keypoints"]
        predicted_keypoints = model(image).view(-1,15,2)
        loss += criterion(
            torch.squeeze(keypoints),
            torch.squeeze(predicted_keypoints)
        ).item()
    return 1.0 / (2 * (loss/len(dataloader)))
print("Score:", evaluate_model(dummy_model, val_dataset))
```

Submission Requirement: Score >= 100



Nos vemos el próximo lunes ©